Univerzitet u Beogradu
Matematički fakultet
Kurs: Istraživanje podataka 2

Predikcija kreditnog rizika primenom algoritama mašinskog učenja

Klasifikacija pomoću algoritama mašinskog učenja

Student: Marko Petrović
Broj indeksa: 131/2020
Profesorka: dr Mirjana Maljković Ružičić

Beograd, mart 2026.

Sadržaj

1 Uvod **3**
1.1 Motivacija . . . 3
1.2 Cilj rada . . . 3

2 Opis podataka **3**
2.1 Izvor podataka . . . 3
2.2 Karakteristike skupa podataka . . . 4
2.3 Ključni atributi . . . 4
2.4 Ciljna promenljiva . . . 4

3 Metodologija **5**
3.1 Pristup rešavanju problema . . . 5
3.2 Preprocesiranje podataka . . . 5
3.2.1 Rukovanje nedostajućim vrednostima . . . 5
3.2.2 Obrada anomalija . . . 5
3.2.3 Enkodiranje kategoričkih promenljivih . . . 5
3.2.4 Standardizacija podataka . . . 6
3.2.5 Podela podataka . . . 6
3.2.6 Rukovanje nebalansiranošću klasa . . . 6
3.2.7 Feature Engineering (napredno rešenje) . . . 7
3.3 Algoritmi za klasifikaciju . . . 7
3.3.1 Logistička regresija . . . 7
3.3.2 Decision Tree (Stablo odlučivanja) . . . 7
3.3.3 Random Forest . . . 7
3.3.4 Gradient Boosting . . . 7
3.3.5 K-Nearest Neighbors (KNN) . . . 8
3.3.6 Naive Bayes . . . 8
3.3.7 AdaBoost . . . 8
3.3.8 XGBoost . . . 8
3.3.9 LightGBM . . . 8
3.4 Klasterovanje . . . 8
3.4.1 K-Means algoritam . . . 8
3.4.2 Određivanje optimalnog broja klastera . . . 9
3.5 Optimizacija hiperparametara . . . 9
3.6 Metrike evaluacije . . . 9
3.6.1 Accuracy (Tačnost) . . . 9
3.6.2 Precision (Preciznost) . . . 9
3.6.3 Recall (Odziv) . . . 9
3.6.4 F1-Score . . . 10
3.6.5 ROC-AUC . . . 10

3.6.6 Cross-Validation 10

4 Rezultati **11**
4.1 Eksplorativna analiza 11
4.1.1 Distribucija klasa 11
4.1.2 Distribucija numeričkih atributa 12
4.1.3 Korelaciona analiza 13
4.1.4 PCA vizualizacija 15
4.2 Performanse modela – Jednostavno rešenje 15
4.3 Performanse modela – Napredno rešenje (∼300 atributa) 16
4.4 Poređenje jednostavnog i naprednog rešenja 16
4.5 Poređenje modela – Vizualizacija 17
4.6 ROC krive 18
4.7 Confusion Matrix 19
4.8 Poređenje: svi atributi vs redukovani 20
4.9 Boosting modeli 20
4.9.1 ROC krive – Boosting modeli 21
4.10 Feature Importance 21
4.11 Klasterovanje 22
4.11.1 Elbow i Silhouette analiza 22
4.11.2 Vizualizacija klastera 23
4.11.3 t-SNE vizualizacija 23
4.12 Rezultati optimizacije hiperparametara 24

5 Diskusija **25**
5.1 Analiza rezultata 25
5.1.1 Najbolji performeri 25
5.1.2 Efekat feature engineering-a 25
5.1.3 Efekat optimizacije hiperparametara 25
5.1.4 Overfitting i generalizacija 25
5.2 Analiza specifičnih modela 26
5.2.1 Uticaj strategija za nebalansiranost klasa 26
5.3 Praktične implikacije 27
5.4 Ograničenja 27

6 Zaključak **28**
6.1 Ključni nalazi 28

7 Literatura **28**

1 Uvod

1.1 Motivacija

Kreditni rizik predstavlja jedan od ključnih izazova u bankarskom sektoru. Sposobnost predviđanja da li će klijent vratiti kredit direktno utiče na profitabilnost i stabilnost finansijskih institucija. Primena algoritama mašinskog učenja omogućava automatizovanu procenu rizika na osnovu istorijskih podataka.

1.2 Cilj rada

Glavni ciljevi ovog rada su:

- Preprocesiranje i priprema podataka za analizu (osnovno i napredno)
- Vizuelno predstavljanje podataka i eksplorativna analiza
- Implementacija i evaluacija 9 algoritama za klasifikaciju
- Primena klasterovanja (K-Means) za otkrivanje grupa u podacima
- Optimizacija hiperparametara najboljeg modela
- Identifikacija najboljeg pristupa za predikciju kreditnog rizika

2 Opis podataka

2.1 Izvor podataka

Home Credit Default Risk dataset je preuzet sa Kaggle platforme. Dataset sadrži podatke o kreditnim prijavama i istoriji klijenata.

URL: `https://www.kaggle.com/c/home-credit-default-risk`

- **Tip problema:** Binarna klasifikacija
- **Oblast:** Finansije, kreditni rizik

2.2 Karakteristike skupa podataka

Tabela 1: Osnovne karakteristike dataseta

Karakteristika	**Vrednost**
Broj instanci	307,511
Broj atributa (osnovna tabela)	122
Broj atributa (nakon feature engineering-a)	∼300
Tip atributa	Numerički i kategorički
Broj klasa	2 (Vratio kredit, Default)
Nedostajuće vrednosti	Da (različit procenat po atributima)

Podaci dolaze iz više izvora:

1. **application_train.csv** – glavna tabela sa podacima o prijavama
2. **bureau.csv** – istorija kredita kod drugih institucija
3. **bureau_balance.csv** – mesečni bilans bureau kredita
4. **previous_application.csv** – prethodne prijave kod Home Credit-a
5. **POS_CASH_balance.csv** – mesečni bilans POS kredita
6. **credit_card_balance.csv** – mesečni bilans kreditnih kartica
7. **installments_payments.csv** – istorija plaćanja rata

2.3 Ključni atributi

Tabela 2: Ključni atributi dataseta

Atribut	**Opis**
AMT_INCOME_TOTAL	Ukupni prihodi klijenta
AMT_CREDIT	Iznos kredita
AMT_ANNUITY	Godišnja rata
DAYS_BIRTH	Starost klijenta (u danima)
DAYS_EMPLOYED	Radni staž (u danima)
EXT_SOURCE_1, 2, 3	Eksterni skorovi iz drugih izvora

2.4 Ciljna promenljiva

Ciljna promenljiva TARGET predstavlja binarnu klasifikaciju:

- **0 (Vratio kredit):** 282,686 instanci (91.9%)
- **1 (Default):** 24,825 instanci (8.1%)

Dataset je značajno nebalansiran, što zahteva pažljiv izbor evaluacionih metrika i specijalne tehnike pri treniranju modela.

3 Metodologija

3.1 Pristup rešavanju problema

Problem je rešen kroz četiri faze:

1. **Jednostavno rešenje** – korišćenje samo osnovne tabele sa bazičnim preprocesiranjem
2. **Napredno rešenje** – agregacija svih tabela i kreiranje novih atributa (feature engineering)
3. **Klasterovanje i Boosting** – analiza klastera i primena naprednih algoritama
4. **Optimizacija hiperparametara** – fino podešavanje najboljeg modela (LightGBM) pomoću RandomizedSearchCV

3.2 Preprocesiranje podataka

3.2.1 Rukovanje nedostajućim vrednostima

- **Numeričke kolone:** Popunjavanje medijanom vrednosti
- **Kategoričke kolone:** Popunjavanje vrednošću “Missing”

3.2.2 Obrada anomalija

Atribut DAYS_EMPLOYED je imao anomalnu vrednost 365243 za nezaposlene/penzionere. Ova vrednost je zamenjena sa NaN i kreiran je dodatni binarni atribut DAYS_EMPLOYED_ANOMALY.

3.2.3 Enkodiranje kategoričkih promenljivih

Kategoričke promenljive su transformisane u numeričke vrednosti korišćenjem Label Encoding metode.

3.2.4 Standardizacija podataka

Primenjena je Z-score standardizacija (StandardScaler) koja transformiše podatke tako da imaju srednju vrednost 0 i standardnu devijaciju 1:

$$z = \frac{x - \mu}{\sigma} \tag{1}$$

gde je: x – originalna vrednost, μ – srednja vrednost, σ – standardna devijacija.

3.2.5 Podela podataka

Skup podataka je podeljen na trening i test skup u odnosu 80:20, uz korišćenje stratifikovane podele kako bi se očuvala raspodela klasa.

3.2.6 Rukovanje nebalansiranošću klasa

Dataset je značajno nebalansiran (91.9% klasa 0 naspram 8.1% klasa 1, odnos $\sim$11.4:1). Bez posebnog tretmana, modeli teže da predviđaju sve instance kao većinsku klasu, što rezultira visokim accuracy ali ekstremno niskim recall za defaulte.

Primenjene su sledeće strategije:

- **Bez balansiranja** (jednostavno rešenje) – služi kao bazna linija za poređenje. Modeli koriste podrazumevani prag 0.5, što dovodi do recall ≈ 0 za klasu default.
- **class_weight='balanced'** (napredno rešenje) – automatski dodeljuje veće težine manjinskoj klasi tokom treniranja. Primenjen na Logističku regresiju, Decision Tree i Random Forest. Težina klase 1 iznosi $\sim$11.4, a klase 0 $\sim$0.54.
- **scale_pos_weight** (boosting modeli) – ekvivalentan parametar za XGBoost i LightGBM koji skalira gubitak za pozitivnu klasu. Postavljen na vrednost 11.39.

Ove tehnike spadaju u pristup *cost-sensitive learning* – ne menjaju sam dataset, već prilagođavaju funkciju gubitka tokom optimizacije. Prednost ovog pristupa u odnosu na resampling tehnike (SMOTE, undersampling) je što ne narušava originalnu distribuciju podataka i ne zahteva generisanje sintetičkih uzoraka.

3.2.7 Feature Engineering (napredno rešenje)

U naprednom rešenju kreirani su dodatni atributi agregacijom podataka iz svih tabela:

- Statistike kredita iz bureau-a (min, max, mean, sum)
- Broj odobrenih/odbijenih prethodnih prijava
- Prosečno kašnjenje u plaćanju rata
- Racio duga prema kreditu

Ukupan broj atributa nakon feature engineering-a: ∼300

3.3 Algoritmi za klasifikaciju

U radu je implementirano 9 različitih algoritama mašinskog učenja:

3.3.1 Logistička regresija

Linearni model koji modelira verovatnoću pripadnosti klasi korišćenjem logističke funkcije:

$$P(y = 1|X) = \frac{1}{1 + e^{-(\beta_0+\beta_1 x_1+...+\beta_n x_n)}} \tag{2}$$

3.3.2 Decision Tree (Stablo odlučivanja)

Stablo odlučivanja gradi model u obliku strukture stabla gde svaki čvor predstavlja test na atributu.

- **Parametri:** max_depth = 10, random_state = 42

3.3.3 Random Forest

Random Forest je ansambl metoda koja koristi više stabala odlučivanja i kombinuje njihove predikcije glasanjem.

- **Parametri:** n_estimators = 100, random_state = 42

3.3.4 Gradient Boosting

Gradient Boosting gradi ansambl slabih modela sekvencijalno, gde svaki sledeći model pokušava da ispravi greške prethodnih.

- **Parametri:** n_estimators = 100, random_state = 42

3.3.5 K-Nearest Neighbors (KNN)

KNN klasifikuje instance na osnovu klasa K najbližih suseda u feature prostoru.

- **Parametri:** n_neighbors = 5

3.3.6 Naive Bayes

Naive Bayes klasifikator zasnovan na Bayes-ovoj teoremi sa pretpostavkom nezavisnosti između atributa:

$$P(y|X) = \frac{P(X|y) \cdot P(y)}{P(X)} \tag{3}$$

3.3.7 AdaBoost

Adaptivni boosting koji iterativno trenira slabe klasifikatore, dajući veću težinu pogrešno klasifikovanim instancama.

- **Parametri:** n_estimators = 100, random_state = 42

3.3.8 XGBoost

Optimizovana implementacija gradient boosting-a sa regularizacijom i paralelizacijom.

- **Parametri:** scale_pos_weight za balansiranje klasa

3.3.9 LightGBM

Brza i efikasna implementacija gradient boosting-a koja koristi leaf-wise strategiju rasta stabla.

- **Parametri:** scale_pos_weight za balansiranje klasa

3.4 Klasterovanje

3.4.1 K-Means algoritam

K-Means je primenjen za otkrivanje prirodnih grupa u podacima. Algoritam iterativno dodeljuje tačke najbližem centroidu i ažurira centroide. Pre klasterovanja, primenjena je PCA redukcija na 50 komponenti koje zadržavaju $\sim$67% varijanse, čime se smanjuje dimenzionalnost i ubrzava računanje.

3.4.2 Određivanje optimalnog broja klastera

Korišćene su tri metode:

1. **Elbow metoda** – traži "lakat" na grafiku inercije
2. **Silhouette score** – meri kvalitet klasterovanja (viša vrednost = bolje)
3. **Calinski-Harabasz i Davies-Bouldin indeksi** – dodatne metrike za validaciju

Optimalan broj klastera prema Silhouette score: $K = 2$

3.5 Optimizacija hiperparametara

Za LightGBM model, koji je pokazao najbolje rezultate, primenjena je dvofazna optimizacija:

1. **RandomizedSearchCV** (50 iteracija, 5-fold CV) – široka pretraga prostora parametara
2. **Fine-tuning** (30 iteracija) – precizno podešavanje oko najboljih vrednosti

3.6 Metrike evaluacije

3.6.1 Accuracy (Tačnost)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{4}$$

Procenat svih tačno klasifikovanih uzoraka. Kod nebalansiranih podataka može biti varljiv.

3.6.2 Precision (Preciznost)

$$Precision = \frac{TP}{TP + FP} \tag{5}$$

Od svih kredita koje je model predvideo kao default, koliki procenat je zaista default.

3.6.3 Recall (Odziv)

$$Recall = \frac{TP}{TP + FN} \tag{6}$$

Od svih stvarnih defaulta, koliki procenat je model uspeo da detektuje. Za banku je recall često važnija metrika jer je cena propuštenog defaulta visoka.

3.6.4 F1-Score

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \tag{7}$$

Harmonijska sredina precision i recall.

3.6.5 ROC-AUC

Površina ispod ROC krive. Meri sposobnost modela da razlikuje klase na svim mogućim pragovima. Interpretacija: AUC = 0.5 (nasumično), 0.7–0.8 (dobar), 0.8–0.9 (vrlo dobar), >0.9 (odličan).

3.6.6 Cross-Validation

Korišćena je 5-fold stratifikovana kros-validacija za robusnu procenu performansi modela.

4 Rezultati

4.1 Eksplorativna analiza

4.1.1 Distribucija klasa

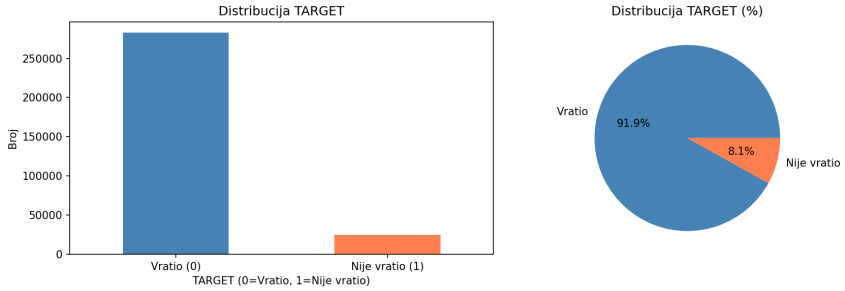

Slika 1: Distribucija ciljne promenljive TARGET. Dataset je značajno nebalansiran sa 91.9% vraćenih kredita i 8.1% defaulta.

4.1.2 Distribucija numeričkih atributa

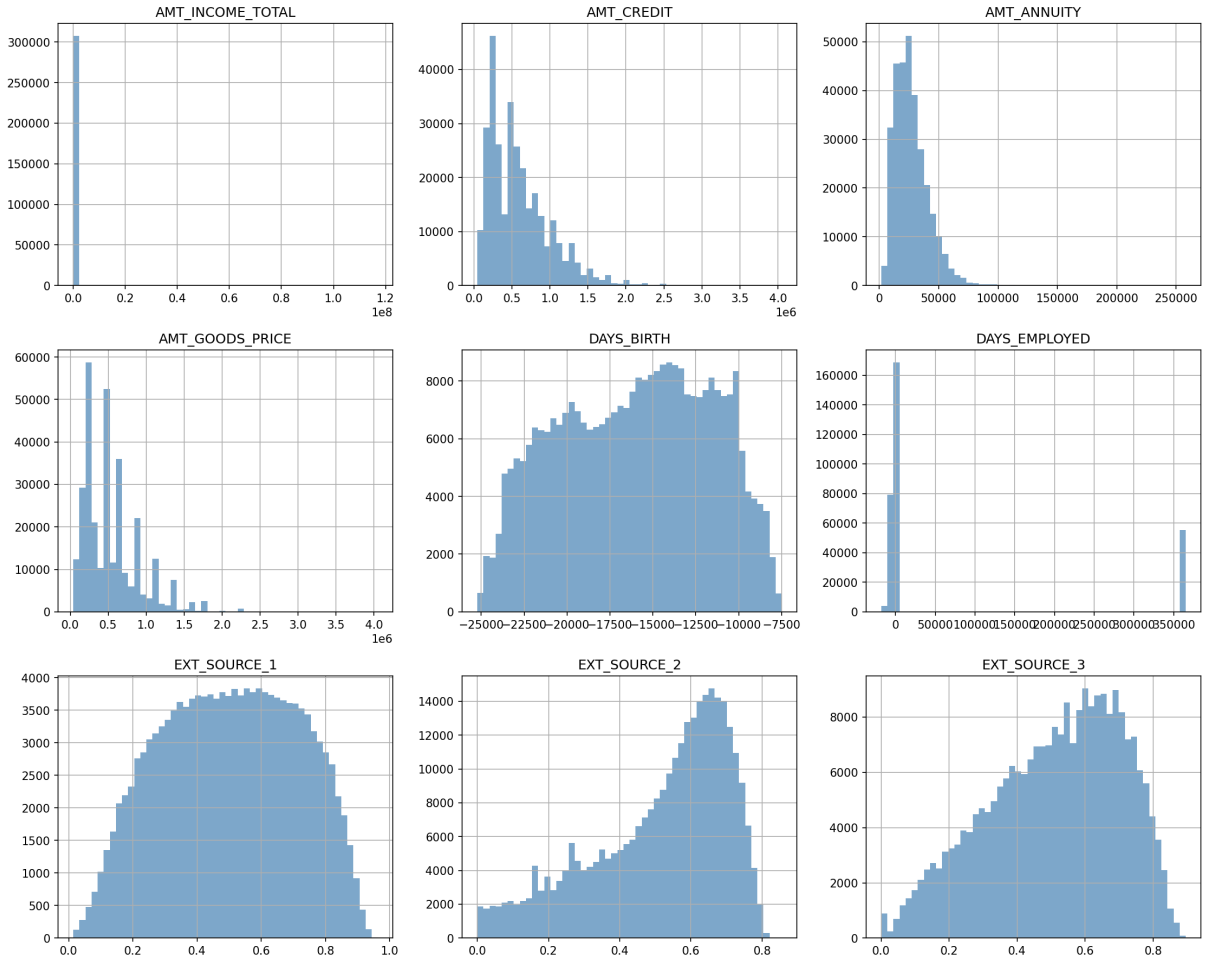

Slika 2: Distribucije ključnih numeričkih atributa (AMT_INCOME_TOTAL, AMT_CREDIT, DAYS_BIRTH, EXT_SOURCE itd.)

4.1.3 Korelaciona analiza

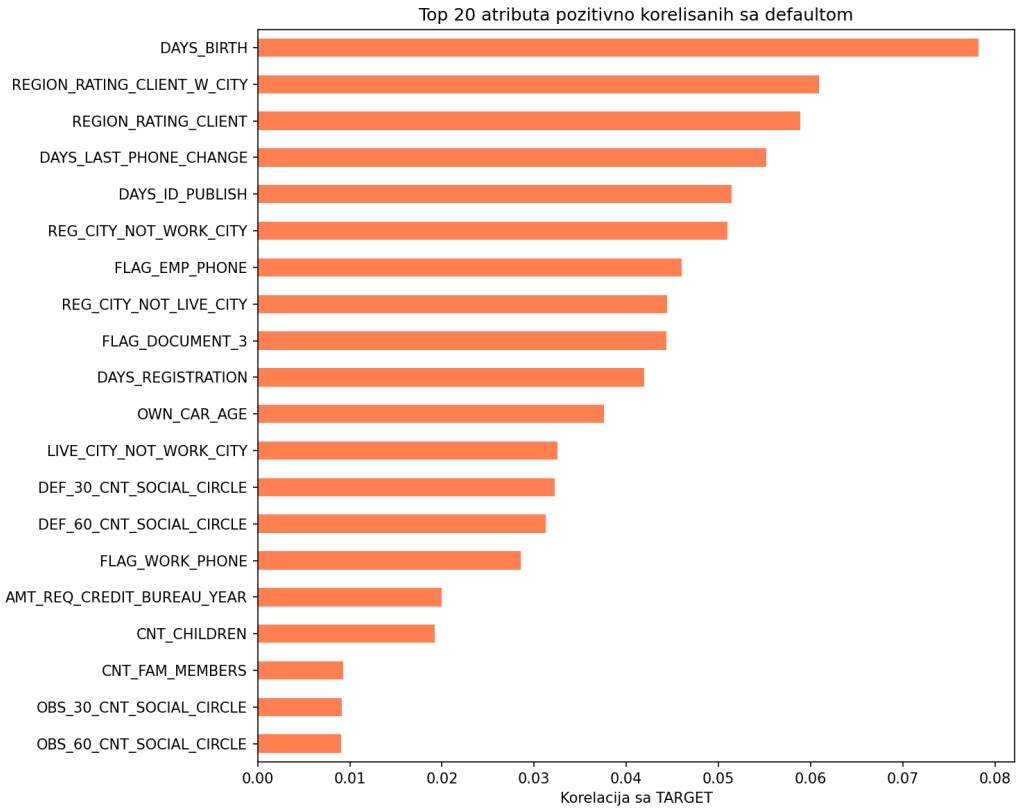

Slika 3: Top 20 atributa pozitivno korelisanih sa defaultom.

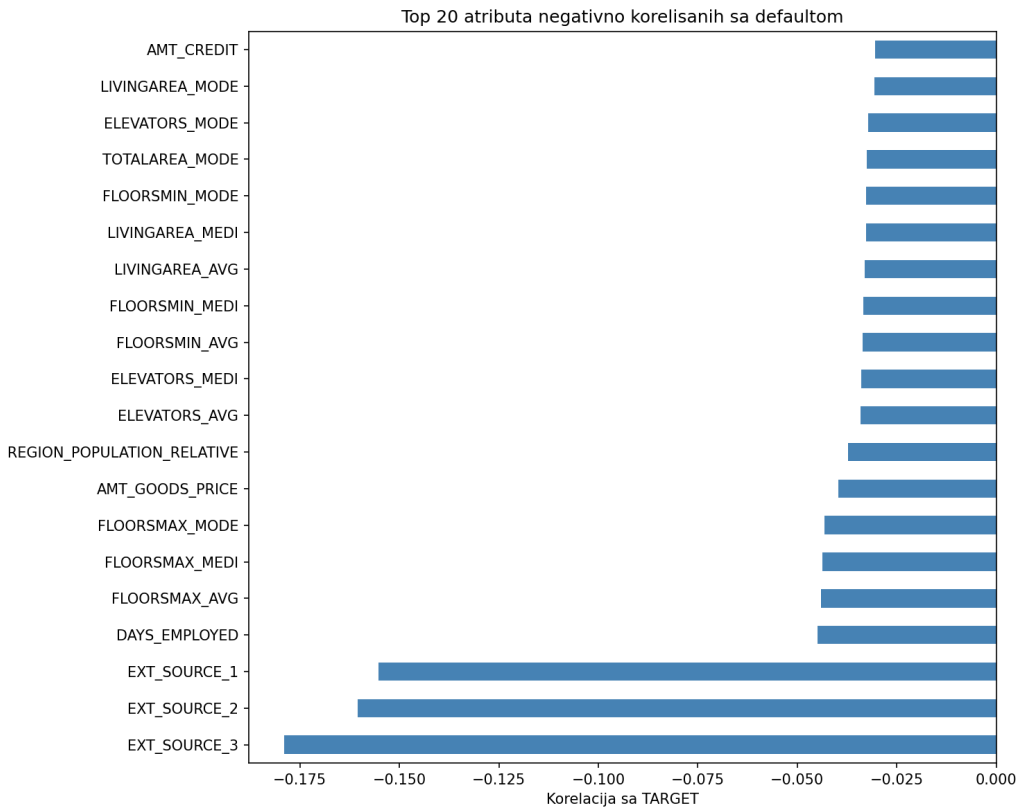

Slika 4: Top 20 atributa negativno korelisanih sa defaultom. Eksterni skorovi (EXT_SOURCE) pokazuju najjaču negativnu korelaciju.

4.1.4 PCA vizualizacija

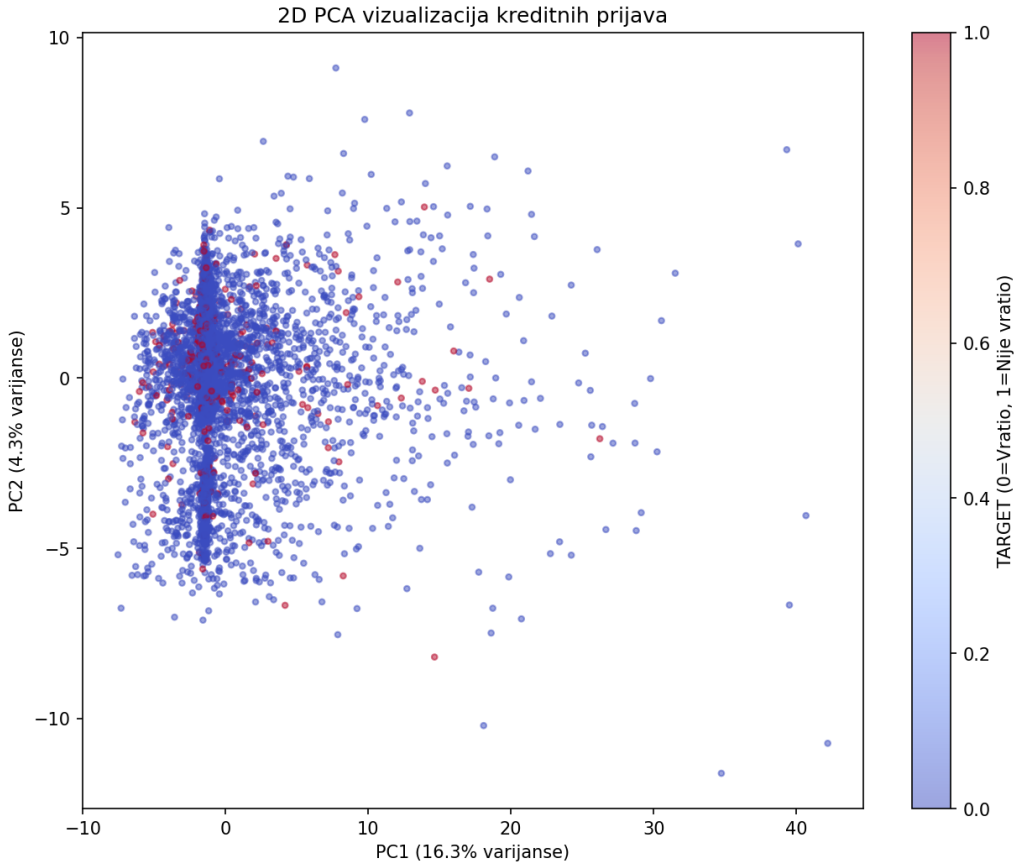

Slika 5: PCA 2D vizualizacija podataka obojenih prema TARGET promenljivoj. Klase se značajno preklapaju u 2D prostoru, što potvrđuje složenost problema klasifikacije.

4.2 Performanse modela – Jednostavno rešenje

Tabela 3: Rezultati modela – jednostavno rešenje

Model	**Accuracy**	**ROC-AUC**	**Recall**	**F1-Score**
Gradient Boosting	0.920	0.757	0.021	0.040
AdaBoost	0.920	0.747	0.011	0.021
Logistička regresija	0.919	0.747	0.011	0.021
Random Forest	0.919	0.739	0.000	0.000
Decision Tree	0.917	0.711	0.021	0.040
Naive Bayes	0.913	0.611	0.006	0.010
KNN	0.914	0.554	0.018	0.033

Napomena: Svi modeli u jednostavnom rešenju koriste podrazumevani prag odlučivanja (0.5). Zbog ekstremne nebalansiranosti dataseta (91.9% na-

spram 8.1%), modeli retko predviđaju defaulte, što rezultira niskim recall i F1 vrednostima.

4.3 Performanse modela – Napredno rešenje (∼300 atributa)

Tabela 4: Rezultati modela – napredno rešenje

Model	Accuracy	ROC-AUC	Recall	F1-Score
Gradient Boosting	0.920	0.780	0.044	0.080
Logistička regresija	0.706	0.770	0.696	0.276
AdaBoost	0.920	0.766	0.016	0.031
Random Forest	0.757	0.760	0.606	0.287
Decision Tree	0.672	0.694	0.642	0.240
Naive Bayes	0.185	0.611	0.920	0.154
KNN	0.914	0.549	0.016	0.029

Napomena: U naprednom rešenju, neki modeli koriste balansiranje klasa (class_weight), što menja prag odlučivanja – Logistička regresija, Random Forest i Decision Tree imaju značajno viši recall ali niži accuracy.

4.4 Poređenje jednostavnog i naprednog rešenja

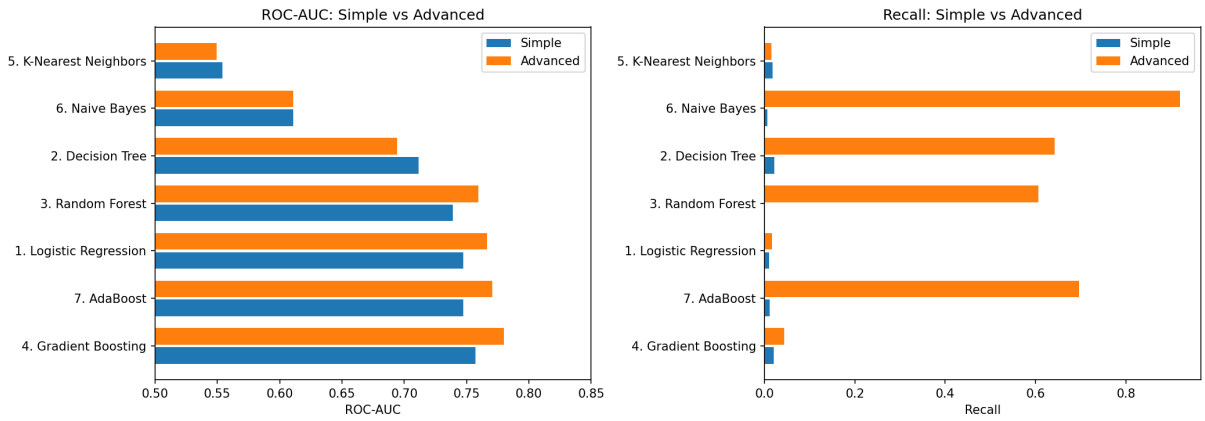

Slika 6: Direktno poređenje jednostavnog i naprednog rešenja po ROC-AUC i Recall. Feature engineering značajno poboljšava detekciju defaulta.

4.5 Poređenje modela – Vizualizacija

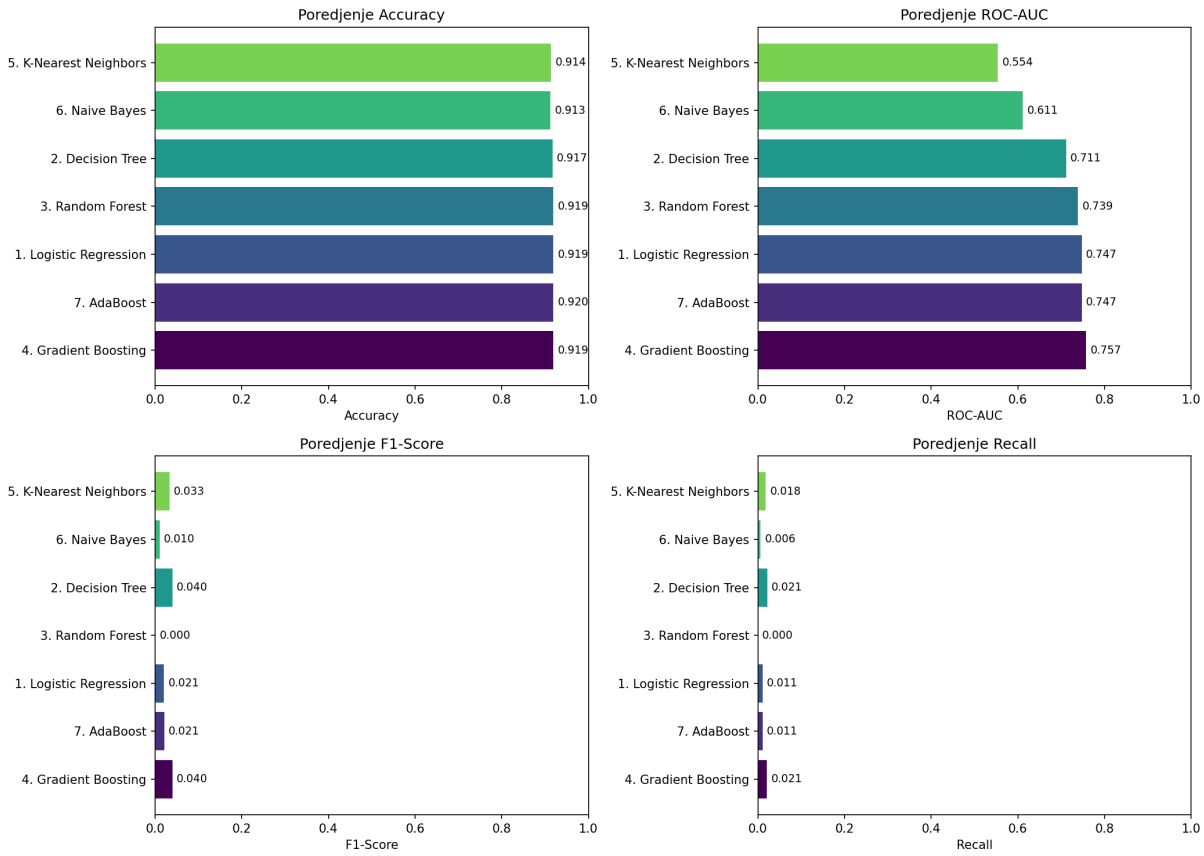

Slika 7: Poređenje performansi svih modela po metrikama Accuracy, ROC-AUC, F1-Score i Recall.

4.6 ROC krive

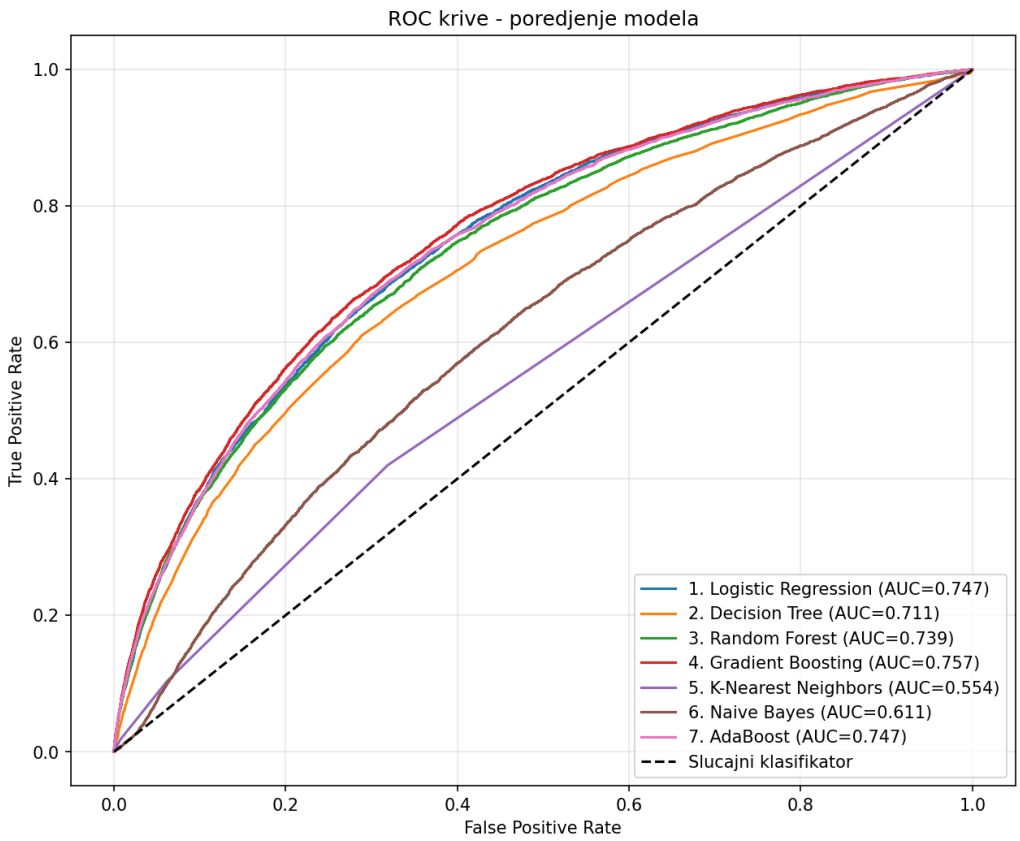

Slika 8: ROC krive za sve modele u jednostavnom rešenju. Gradient Boosting i Random Forest pokazuju najbolje rezultate.

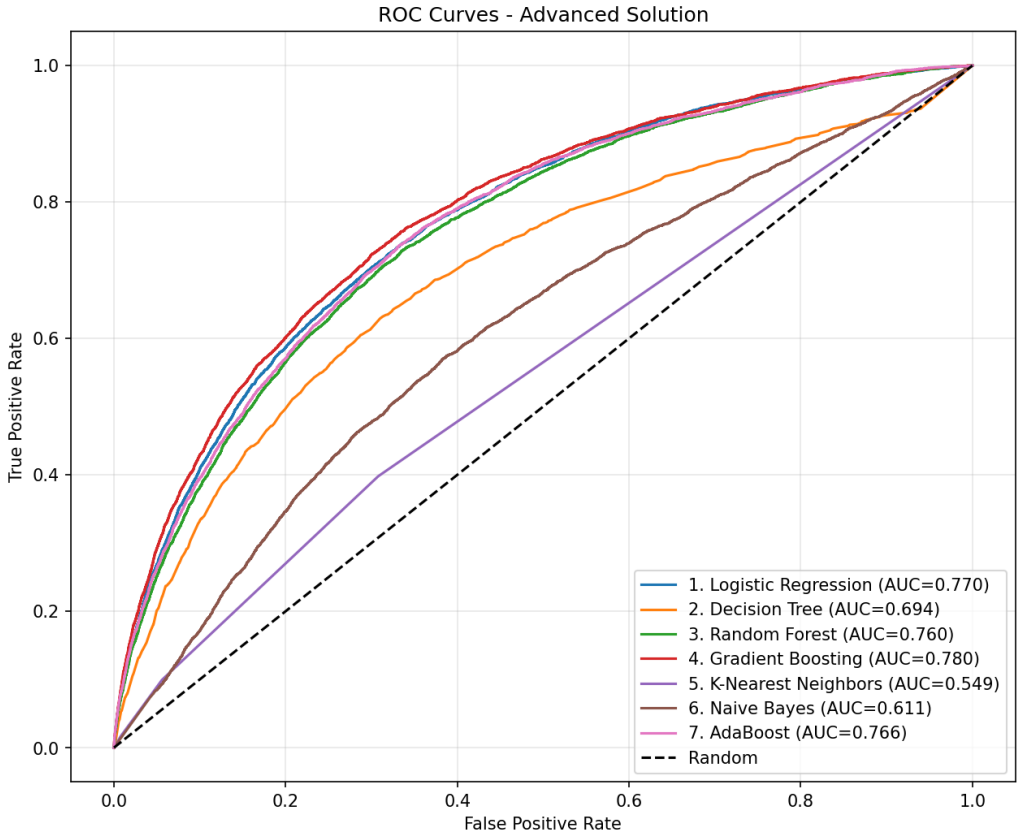

Slika 9: ROC krive za modele u naprednom rešenju. Feature engineering poboljšava AUC za većinu modela.

4.7 Confusion Matrix

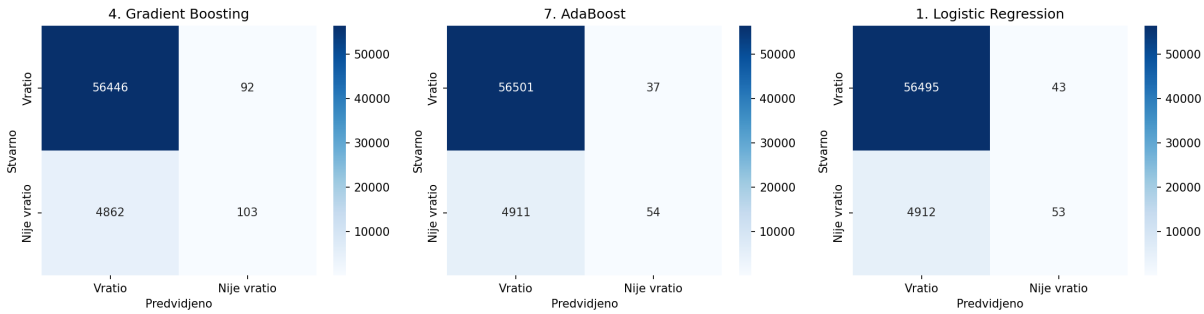

Slika 10: Matrice konfuzije za top 3 modela (jednostavno rešenje).

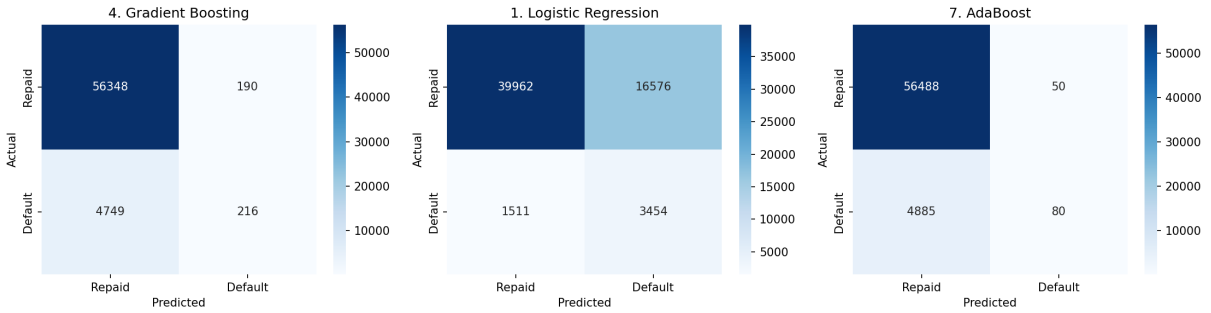

Slika 11: Matrice konfuzije za top 3 modela (napredno rešenje). Modeli sa class_weight='balanced' pokazuju značajno viši recall.

4.8 Poređenje: svi atributi vs redukovani

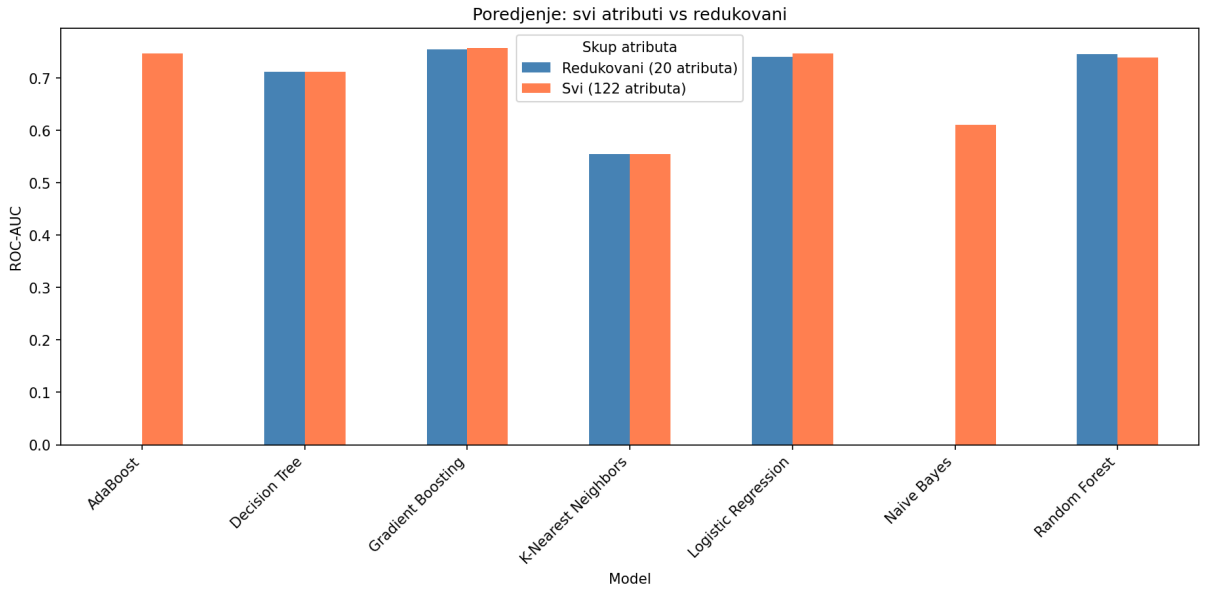

Slika 12: Poređenje performansi modela sa svim atributima (122) nasuprot redukovanom skupu (20 atributa).

4.9 Boosting modeli

Tabela 5: Rezultati boosting modela

Model	Accuracy	ROC-AUC	Recall
LightGBM (Optimized)	0.740	**0.787**	0.690
LightGBM	0.745	0.784	0.678
XGBoost	0.762	0.782	0.646

Napomena: Boosting modeli koriste scale_pos_weight parametar za balansiranje klasa, zbog čega imaju znatno viši recall ali niži accuracy u poređenju sa podrazumevanim pragom.

4.9.1 ROC krive – Boosting modeli

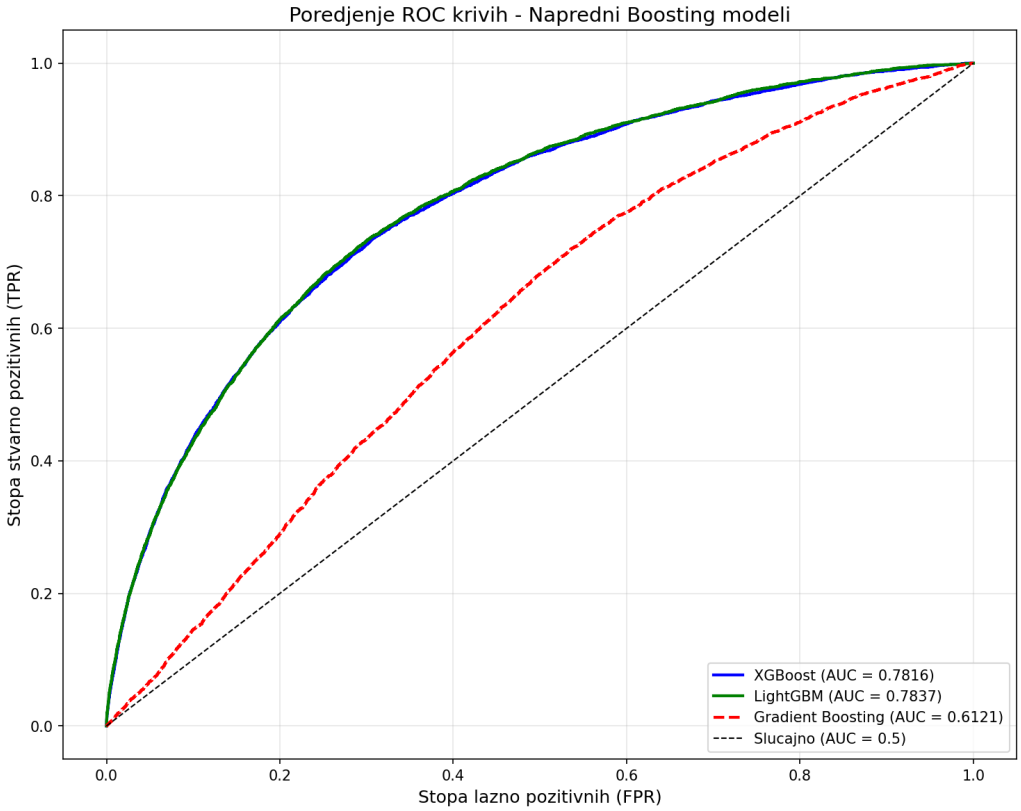

Slika 13: ROC krive za XGBoost, LightGBM i Gradient Boosting. LightGBM postiže najbolji AUC od 0.787.

4.10 Feature Importance

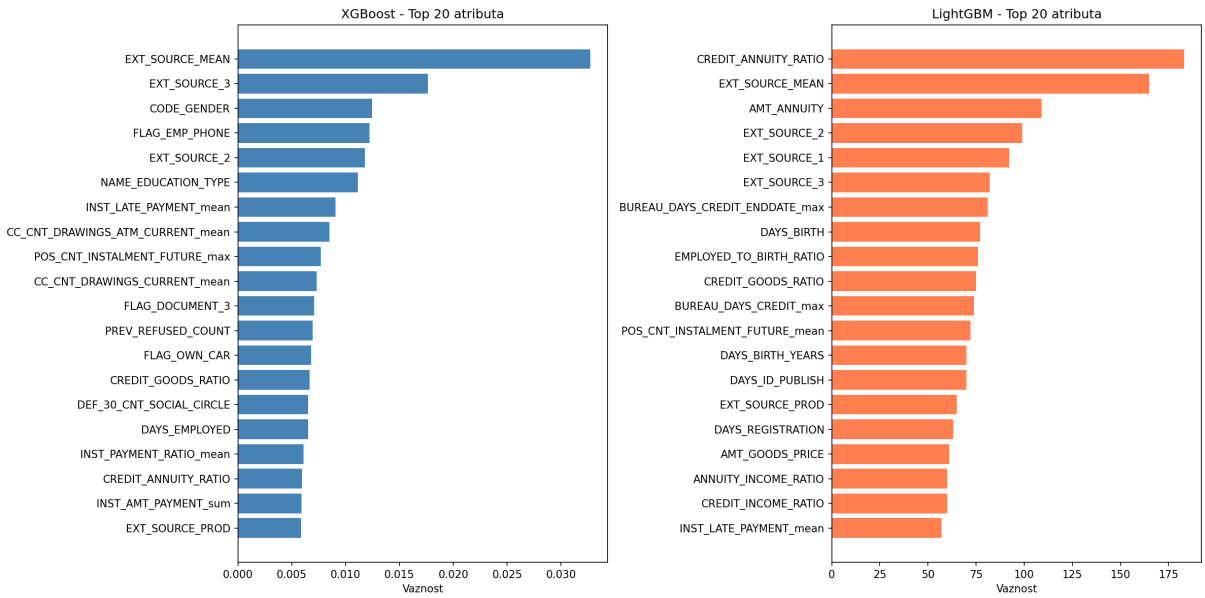

Slika 14: Važnost atributa prema XGBoost i LightGBM modelima. Eksterni skorovi (EXT_SOURCE) su najpredikcivniji atributi.

Top 10 atributa po važnosti:

1. EXT_SOURCE_2
2. EXT_SOURCE_3
3. EXT_SOURCE_1
4. DAYS_BIRTH
5. DAYS_EMPLOYED
6. AMT_CREDIT
7. AMT_ANNUITY
8. AMT_GOODS_PRICE
9. DAYS_ID_PUBLISH
10. DAYS_REGISTRATION

4.11 Klasterovanje

4.11.1 Elbow i Silhouette analiza

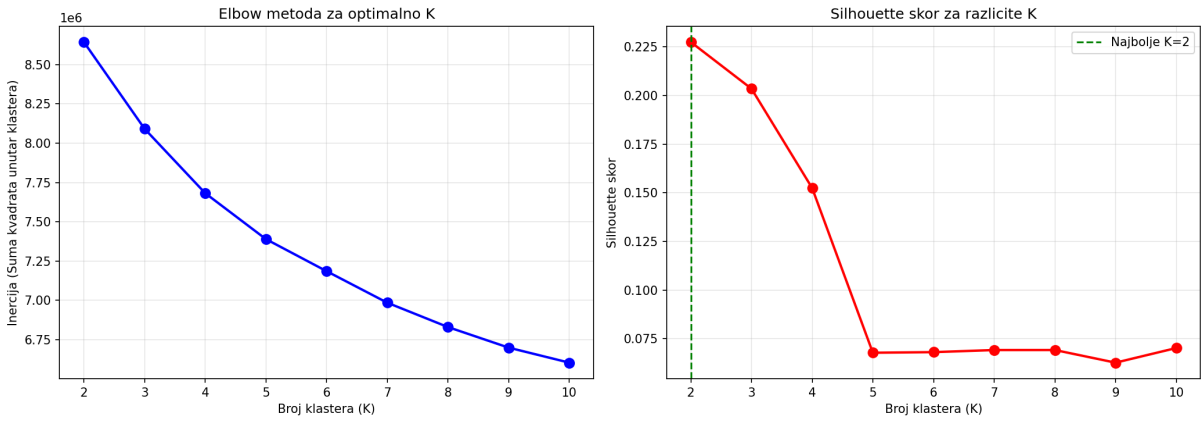

Slika 15: Elbow metoda i Silhouette Score za određivanje optimalnog broja klastera.

4.11.2 Vizualizacija klastera

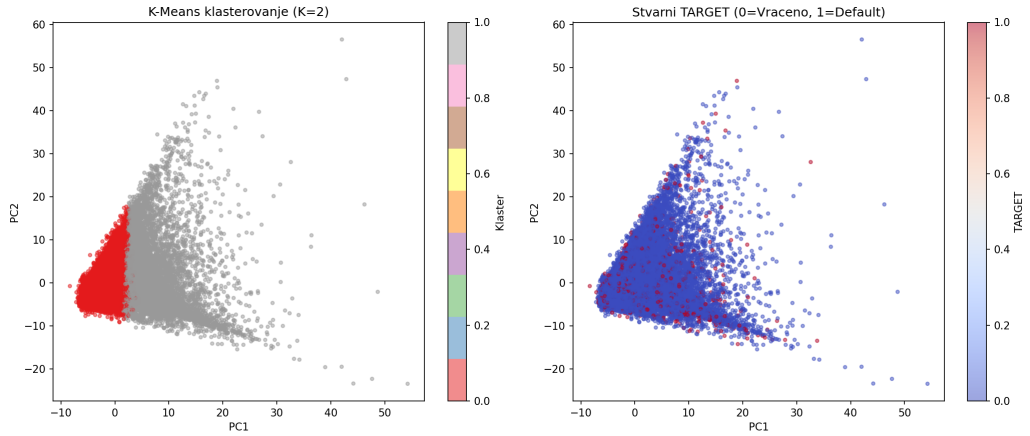

Slika 16: Poređenje K-Means klastera ($K = 2$) sa stvarnom TARGET promenljivom u PCA prostoru.

4.11.3 t-SNE vizualizacija

t-SNE (t-distributed Stochastic Neighbor Embedding) je primenjen na uzorku od 10,000 instanci kao nelinearni metod za redukciju dimenzionalnosti na 2D prostor. Za razliku od PCA koji čuva globalnu strukturu, t-SNE bolje prikazuje lokalne klastere i grupacije.

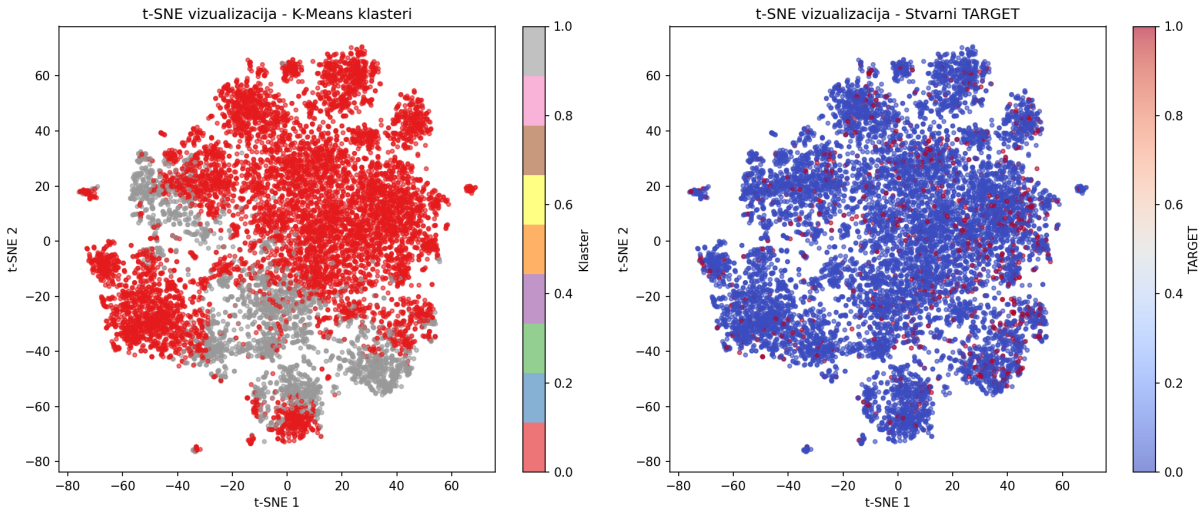

Slika 17: t-SNE vizualizacija: K-Means klasteri (levo) i stvarni TARGET (desno). Parametri: perplexity=30, max_iter=1000.

Tabela 6: Metrike klasterovanja ($K = 2$)

Metrika	**Vrednost**
Silhouette Score	0.2155
Calinski-Harabasz Index	3,259.07
Davies-Bouldin Index	2.8596

Relativno nizak Silhouette Score (0.22) i visok Davies-Bouldin indeks (2.86) pokazuju da klijenti ne formiraju jasno odvojene grupe. Stope defaulta u oba klastera su gotovo identične (∼8.1%), što ukazuje da linearna separacija u PCA prostoru ne uspeva da razdvoji rizične od nerizičnih klijenata. Ovo je uobičajeno za finansijske podatke gde su granice između kategorija nejasne i gde su supervizovane metode (poput gradient boosting-a) značajno efikasnije.

4.12 Rezultati optimizacije hiperparametara

Optimalni parametri za LightGBM:

Tabela 7: Optimalni hiperparametri LightGBM modela

Parametar	**Vrednost**
n_estimators	600
max_depth	7
learning_rate	0.025
num_leaves	31
min_child_samples	90
subsample	0.9
colsample_bytree	0.9
reg_alpha	1
reg_lambda	0

Progresija optimizacije:

Tabela 8: Progresija optimizacije hiperparametara

Faza	**ROC-AUC**	**Poboljšanje**
Bazni model	0.7837	–
RandomizedSearchCV	0.7868	+0.31%
Fine-tuned	0.7872	+0.35%

5 Diskusija

5.1 Analiza rezultata

5.1.1 Najbolji performeri

- Boosting algoritmi (LightGBM, XGBoost) su pokazali najbolje performanse sa ROC-AUC > 0.78
- Ansambl metode (Random Forest, Gradient Boosting) su konzistentno dobre
- Feature engineering je doprineo poboljšanju – ROC-AUC je porastao sa 0.757 na 0.780 za Gradient Boosting

5.1.2 Efekat feature engineering-a

Napredno rešenje sa ∼300 atributa je poboljšalo ROC-AUC rezultate za većinu modela:

- Gradient Boosting: 0.757 → 0.780 (+3.0%)
- Logistička regresija: 0.747 → 0.770 (+3.1%)
- Random Forest: 0.739 → 0.760 (+2.8%)
- KNN: 0.554 → 0.549 (bez poboljšanja – prokletstvo dimenzionalnosti)

5.1.3 Efekat optimizacije hiperparametara

Optimizacija je donela skromno poboljšanje (∼0.35%), što ukazuje da su podrazumevani parametri LightGBM-a već bili blizu optimalnih za ovaj dataset (bazni ROC-AUC 0.784 → optimizovani 0.787).

5.1.4 Overfitting i generalizacija

Cross-validation rezultati optimizovanog LightGBM modela su konzistentni sa test rezultatima, što ukazuje da model dobro generalizuje i nije prefitovan.

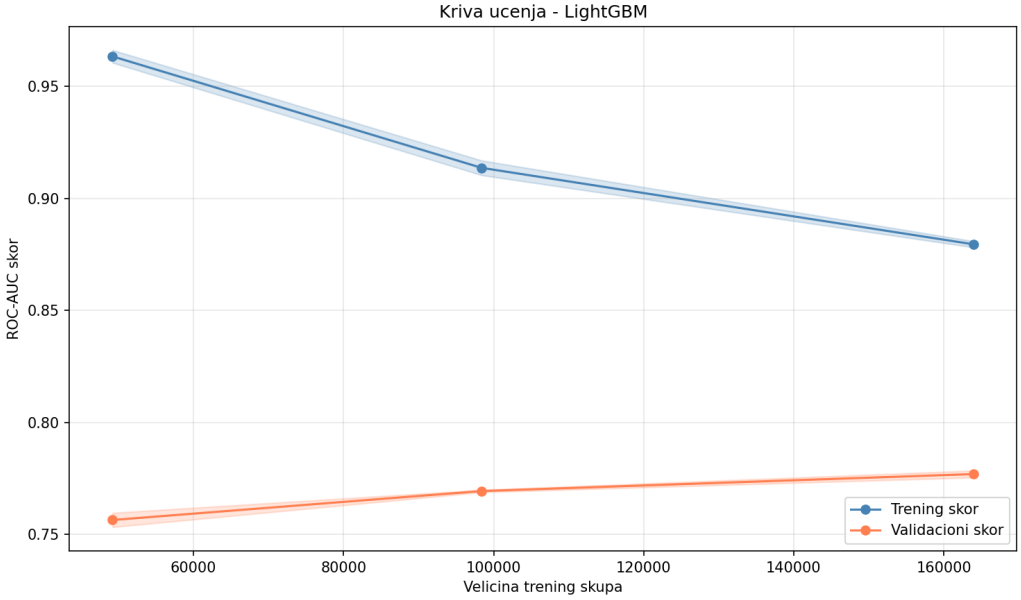

Slika 18: Kriva učenja LightGBM modela. Trening i validacione krive konvergiraju što ukazuje da model dobro generalizuje.

5.2 Analiza specifičnih modela

Zašto većina modela u jednostavnom rešenju ima Recall $\approx$ 0?
Sa podrazumevanim pragom odlučivanja (0.5), modeli na ekstremno nebalansiranim podacima (91.9% : 8.1%) predviđaju skoro sve kao klasu 0 ("vraćeno"). ROC-AUC je pouzdanija metrika jer meri sposobnost rangiranja nezavisno od praga.

Zašto Naive Bayes u naprednom rešenju ima accuracy od 18.5%?
Naive Bayes predviđa skoro sve instance kao default (Recall = 0.920), što drastično smanjuje accuracy. Ovo je posledica pretpostavke nezavisnosti atributa koja ne važi za ovaj dataset sa $\sim$300 korelisanih atributa.

Zašto KNN loše performira (ROC-AUC = 0.554)?
Sa 122+ atributa, "prokletstvo dimenzionalnosti" čini euklidska rastojanja manje smislenim. KNN nije pogodan za visokodimenzionalne podatke i nije se poboljšao ni sa feature engineering-om (0.554 $\rightarrow$ 0.549).

Zašto su boosting modeli najbolji?
Sekvencijalno ispravljaju greške, fokusiraju se na teške slučajeve (defaulte), a scale_pos_weight parametar balansira klase. Ovo omogućava visok recall (0.68–0.69) uz zadržavanje dobrog ROC-AUC ($>$0.78).

5.2.1 Uticaj strategija za nebalansiranost klasa

Poređenje tri pristupa pokazuje značajan uticaj na detekciju defaulta:

Tabela 9: Poređenje strategija za nebalansiranost (na primeru Random Forest)

Strategija	**Accuracy**	**Recall**	**ROC-AUC**
Bez balansiranja (NB01)	0.919	0.000	0.739
class_weight='balanced' (NB02)	0.757	0.606	0.760

Bez balansiranja, model postizao je 91.9% accuracy ali je potpuno ignorisao defaulte (recall = 0). Sa class_weight='balanced', recall je porastao na 60.6% uz pad accuracy na 75.7%. Za banku, detekcija 60% umesto 0% defaulta predstavlja ogromnu praktičnu razliku.

Boosting modeli sa scale_pos_weight postižu najoptimalniji balans: recall ∼69% uz ROC-AUC od 0.78+, što ih čini najboljim izborom za primenu u praksi.

5.3 Praktične implikacije

Rezultati ovog istraživanja imaju praktične primene:

- **Najbolji model:** LightGBM (Optimized) sa ROC-AUC = 0.787
- **Recall:** 69.0% – od 100 klijenata koji neće vratiti kredit, model detektuje 69
- **Accuracy:** 74.0% – niži od modela sa podrazumevanim pragom (∼92%) ali sa znatno boljom detekcijom defaulta

Primer primene za 10,000 kreditnih prijava:

- ∼800 stvarnih defaulta (8%)
- Model detektuje ∼552 defaulta (69% od 800)
- ∼248 rizičnih klijenata dobija kredit (lažno negativni)
- Određen broj dobrih klijenata biva odbijen (lažno pozitivni)

5.4 Ograničenja

- Dataset sadrži samo istorijske podatke bez informacija o trenutnom ekonomskom kontekstu
- Neki važni atributi imaju visok procenat nedostajućih vrednosti
- Model može imati pristrasnost prema određenim grupama klijenata
- ROC-AUC od 0.78–0.80 je tipičan za ovaj tip problema – defaulti su inherentno teški za predikciju

6 Zaključak

6.1 Ključni nalazi

1. Implementirano je 9 različitih algoritama za klasifikaciju u 4 faze
2. Najbolje performanse postigao je **LightGBM (Optimized)** sa ROC-AUC = **0.787**
3. Feature engineering je poboljšao ROC-AUC rezultate za većinu modela (Gradient Boosting: 0.757 → 0.780)
4. Optimizacija hiperparametara donosi dodatno poboljšanje (ROC-AUC: 0.784 → 0.787)
5. Eksterni skorovi (EXT_SOURCE) su ključni prediktori kreditnog rizika
6. Klasterovanje pokazuje delimičnu korelaciju sa rizikom, ali separacija nije potpuna

7 Literatura

1. Home Credit Default Risk Competition, Kaggle. https://www.kaggle.com/c/home-credit-default-risk
2. Scikit-learn: Machine Learning in Python – Zvanična dokumentacija. https://scikit-learn.org/stable/
3. XGBoost Documentation. https://xgboost.readthedocs.io/
4. LightGBM Documentation. https://lightgbm.readthedocs.io/
5. Pandas Documentation. https://pandas.pydata.org/docs/
6. NumPy Documentation. https://numpy.org/doc/
7. Matplotlib Documentation. https://matplotlib.org/
8. Aurélien Géron (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*, 2nd Edition. O'Reilly Media.

Projekat izrađen u okviru kursa Istraživanje podataka 2